# Midterm Examine / Categorical Data Analysis

Sheng-Mao Chang

4/30/2026

# Q1: 台灣手機佔有率問題。

某調查針對台灣及香港估計手機品牌市占率，資料顯示如下：

| | Apple | Samsong | OPPO | Xiomi | Others |
|---|---|---|---|---|---|
| Taiwan | 110 | 36 | 12 | 8 | 44 |
| Hong Kong | 50 | 17 | 10 | 0 | 23 |

- (20%) 請利用統計檢定來審視 $H_0: Apple$手機佔有率在台灣為50% vs $H_a: Apple$手機佔有率在台灣不為50%。
- (20%) 請利用Odds Ratio的概念來檢視是否台灣人比香港人更愛用Apple手機。
- (20%) 請檢定是否佔有率與臺港二地是否獨立。

# Q2: 乳癌預測。

- (20%) 這個乳癌資料庫來自University of Wisconsin Hospitals（威斯康辛大學醫院，麥迪遜），由William H. Wolberg醫師提供。其內容為截至 1992 年 7 月 15 日止，對 699 位乳房腫瘤病患的切片檢查結果所進行的評估。九項腫瘤特徵皆以 1 至 10 分量表進行評分，並已知每位病患的最終診斷結果。此資料集共有 699 筆觀測值與 11 個欄位。請建構一預測模型，並執行模型選型，並評價其預測能力。

```
library(MASS)
data(biopsy)
str(biopsy)
```

```
## 'data.frame':    699 obs. of  11 variables:
##  $ ID   : chr  "1000025" "1002945" "1015425" "1016277" ...
##  $ V1   : int  5 5 3 6 4 8 1 2 2 4 ...
##  $ V2   : int  1 4 1 8 1 10 1 1 1 2 ...
##  $ V3   : int  1 4 1 8 1 10 1 2 1 1 ...
##  $ V4   : int  1 5 1 1 3 8 1 1 1 1 ...
##  $ V5   : int  2 7 2 3 2 7 2 2 2 2 ...
##  $ V6   : int  1 10 2 4 1 10 10 1 1 1 ...
##  $ V7   : int  3 3 3 3 3 9 3 3 1 2 ...
##  $ V8   : int  1 2 1 7 1 7 1 1 1 1 ...
##  $ V9   : int  1 1 1 1 1 1 1 1 5 1 ...
##  $ class: Factor w/ 2 levels "benign","malignant": 1 1 1 1 1 2 1 1 1 1 ...
```

變數說明：

- 反應變數： class = benign(良性)； = malignant(惡性)。
- 自變數：
    - v1: 腫塊厚度

- v2: 細胞數
- v3: 細胞平整度
- v4: 邊緣黏附程度
- v5: 上表皮細胞數
- v6: 裸核數
- v7: 均勻染色質數
- v8: 正常核仁數
- v9: 有絲分裂數

```
## remove NA values
sel <- which(is.na(biopsy$V6))
bio2 <- biopsy[-sel,]
## remove id
bio2 <- bio2[,-1]

## first model
out <- glm(class~., data=bio2, family="binomial")
summary(out)
```

```
##
## Call:
## glm(formula = class ~ ., family = "binomial", data = bio2)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept) -10.10394    1.17488  -8.600  < 2e-16 ***
## V1            0.53501    0.14202   3.767 0.000165 ***
## V2           -0.00628    0.20908  -0.030 0.976039
## V3            0.32271    0.23060   1.399 0.161688
## V4            0.33064    0.12345   2.678 0.007400 **
## V5            0.09663    0.15659   0.617 0.537159
## V6            0.38303    0.09384   4.082 4.47e-05 ***
## V7            0.44719    0.17138   2.609 0.009073 **
## V8            0.21303    0.11287   1.887 0.059115 .
## V9            0.53484    0.32877   1.627 0.103788
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 884.35  on 682  degrees of freedom
## Residual deviance: 102.89  on 673  degrees of freedom
## AIC: 122.89
##
## Number of Fisher Scoring iterations: 8
```

# Q3: 住宅滿意度調查

- (20%) 丹麥住宅滿意度調查結果如下：

```
library(MASS)
data(housing)
str(housing)
```

```
## 'data.frame':    72 obs. of  5 variables:
##  $ Sat : Ord.factor w/ 3 levels "Low"<"Medium"<..: 1 2 3 1 2 3 1 2 3 1 ...
##  $ Infl: Factor w/ 3 levels "Low","Medium",..: 1 1 1 2 2 2 3 3 3 1 ...
##  $ Type: Factor w/ 4 levels "Tower","Apartment",..: 1 1 1 1 1 1 1 1 1 2 ...
##  $ Cont: Factor w/ 2 levels "Low","High": 1 1 1 1 1 1 1 1 1 1 ...
##  $ Freq: int  21 21 28 34 22 36 10 11 36 61 ...
```

請用四個自變數(Infl, Type, Cont, Freq) 預測滿意度(sat)。

- 反應變數： sat = Low, Medium, High (住宅滿意度)
- 自變數：
  - Infl: 住戶對於房產管理事務所感受到的影響力程度。
  - Type: 住宅型式 (Tower, Atrium, Apartment, Terrace)。
  - Cont: 住戶與其他住戶之間所獲得的互動機會 (Low, High)。
  - Freq: 住宅內人數。